Concilier les triplets extraits à partir de textes et ceux extraits de bases de connaissances

David ALFONSO HERMELO

Université Paris III Sorbonne Nouvelle david.alfonso.hermelo@gmail.com

12 septembre 2017

Présentation

- Introduction
 - Motivation
- Développement
 - État de l'art et travaux connexes
 - Bases de connaissances
 - Extracteurs d'information libre
 - Analyses
 - Analyses
 - Analyses
 - Résultats
 - Conclusions
 - Contributions
 - Perspectives




Introduction

Introduction

KB (Base de Connaissances):

• Collection de faits attestés (objectifs).



Introduction

OIE (Extracteur d'information libre):

• Collection de triplets non attestés (subjectifs).

INPUT:

Chilly Gonzales is a Canadian musician who resided in Paris for several years, and now lives in Cologne (which is in Germany).

OUTPUT:

Chilly Gonzales: is a: Canadian musician

Gonzales: is: Canadian Cologne: is: in Germany

now lives in Cologne: resided: in Paris for several years


Paris: now lives: in Cologne

which: is: in Germany

Motivation

- Analyse de la complémentarité des KB et des OIE.
 Pourquoi?
- Manque de mesures.
- Les informations subjectives peuvent être utiles:
 - Les vins italiens sont les meilleurs au monde.
 - Les vins français sont les meilleurs au monde.
- Les KB ont des lacunes informatives:





Développement

MÉTHODES

Analyse de l'état de l'art et travaux connexes.

Observation empirique.

Projets KB analysés

Yago			
Yago2			
DBpedia			
Nell			
Wikidata			
Freebase			
Knowledge Graph			
Knowledge Vault			

• Analyse de l'état de l'art et travaux connexes.

MÉTHODES

Observation empirique.

Projets OIE analysés

ReVerb
OLLIE
ClausIE
PropS
CSD-IE
OpenIE-4
Standford Open IE

• Sélection des KB les plus complètes.

MÉTHODES

- Observation empirique.
- Analyse statistique.

	Nb entités (millions)	Nb faits (millions)
YAGO	10	120
NELL	2.98	90
DBpedia	4	580
Deep Dive	0.055	0.980
Wikidata	25	144
Freebase	58	1900
Google Knowledge Graph	1000	70000

Table: Taille approximative de plusieurs KB

• Choix des entités pour analyses.

MÉTHODES

Observation empirique.

Procédure

- 100 entités articles Wikipédia au hasard + 1 entité fétiche.
- Suppression des entités $\neg \exists$ dans les 3 KB les plus complètes.
- 20 entités = requêtes pour analyses.

Freebase

Chilly Gonzales
Hoja en Blanco
Copelatus unguicularis
Ajaigarh State
Clare Mill, California
Hellboy: Blood and Iron
Future Legends
McAlmont & Butler
1987 Rose Bowl
Taranaki rugby league

team

Know. Graph

Chilly Gonzales
Hoja en Blanco
Copelatus unguicularis
Ajaigarh State
Clare Mill, California
Hellboy: Blood and Iron
Future Legends
McAlmont & Butler
1987 Rose Bowl
Taranaki rugby league

Wikidata


Chilly Gonzales
Hoja en Blanco
Copelatus unguicularis
Ajaigarh State
Clare Mill, California
Hellboy: Blood and Iron
Future Legends
McAlmont & Butler
1987 Rose Bowl
Taranaki rugby league

• Sélection des OIE plus compétents.

MÉTHODES

Analyse statistique.

Schéma du banc d'essai extrait de Stanovsky et Dagan (2016).





Analyse des KB sélectionnées.

MÉTHODES

Analyse statistique.

Nous avons compté les faits communs à plusieurs KB.

Choix correspondance S-O ("match"):

Freebase	Chilly Gonzales	music.artist.origin	Montreal
Wikidata	Chilly Gonzales	place of birth	Montreal

Freebase	Chilly Gonzales	music.artist.origin	Montreal
Wikidata	Chilly Gonzales	place of birth	Canada

Analyse des KB sélectionnées

	Freebase	Know. Graph	Wikidata	TOTAL FAITS
Freebase	-	63	60	770
Know. Graph	-	_	39	250
Wikidata [*]	-	-	-	394
TOTAL FAITS	770	250	394	

Table: Tableau de contingence du nombre de faits en commun pour les différentes KB (des 20 E d'échantillon).

MÉTHODES

 Analyse des triplets de sortie des OIE sélectionnés.

ÉTAPES

Analyse statistique.

Nous avons compté les triplets communs à plusieurs OIE.

Choix correspondance S-P-O ("match"):

Phrase 1 - ClausIE	Chilly Gonzales	was born in	Montreal
Phrase 117 - OLLIE	Chilly Gonzales	was born in	Montreal

Phrase 1 - ClausIE	Chilly Gonzales	was born in	Montreal
Phrase 225 - OLLIE	Chilly Gonzales	was born at	Montreal

Phrase 1 - ClausIE	Chilly Gonzales	was born in	Montreal
Phrase 854 - OLLIE	Chilly Gonzales	played at	Montreal

Phrase 45 - ClausIE	His brother	played at	the same concert
Phrase 854 - OLLIE	Chilly Gonzales	played at	Montreal

Analyse des OIE sélectionnées

	ClausIE	OLLIE	OpenIE-4	TOTAL
ClausIE	-	344	583	10501
OLLIE	_	-	0	8331
OpenIE-4	-	-	-	6729
TOTAL	10501	8331	6729	

Table: Tableau de contingence du nombre de triplets en commun en sortie des différentes OIE (des 20 E d'échantillon, avec le contenu des 10 premiers résultats de Google Search + Wikipédia pour entrée d'OIE).

Étapes et méthodes de recherche

ÉTAPES

 Expérimentation comparative triplets de sortie OIE - faits de KB.

MÉTHODES

- Recherche expérimentale.
- Analyse statistique.

	Freebase	Knowledge Graph	Wikidata	TOTAL
ClausIE	4	1	6	10501
OLLIE	0	0	0	8331
OpenIE-4	2	3	4	6729
TOTAL	765	153	404	

Table: ableau de contingence du nombre de triplets en commun en sortie des différentes OIE et KB (des 20 E d'échantillon).



Conceptualisation d'heuristiques.

MÉTHODES

Observation empirique.

Heuristiques

- Union et intersection
- Score de confiance
- Sujet exact
- Sujet entité-partielle
- Sujet dist. Levenshtein
- Sujet dist. word embedding
- Sujet alias
- Sujet pronom



Conceptualisation d'heuristiques.

MÉTHODES

Observation empirique.

- Union et intersection.
- Score de confiance
- Sujet exact
- Sujet entité-partielle
- Sujet dist. Levenshtein
- Sujet dist. word emb.
- Sujet alias
- Sujet pronom

- Chilly Gonzales: composed: a global hit for the inaugural Apple iPad campaign
- he: had re-signed: with a major label it: drew : immediate
- comparisons to the work of Frik Satie
- Gonzales: wrote: music • everyone: to sing : for me
- livre de partitions: à : jouer
- he: would win : a Grammy Award
- Gonzales: was born: on 20 March 1972
- Chilly Gonzales: holds: the Guinness world record for the longest solo concert at over 27 hours

- the artist: took up : residence in Europe mainly in Germany just after signing to Kitty-Yo he: had re-signed : with a maior label it: drew : immediate comparisons to the work of Erik
- Satie
- he: is : songwriter
- Gonzo: shares: his point of view
- écrit des: chansons : avec Jarvis Cocker
- Gonzales: was born: on 20 March 1972 Gonzales also known as Chilly
- Gonzales: is: an MC-meetskeyboarding-producer-meetssinger-extraordinaire

Conceptualisation d'heuristiques.

MÉTHODES

• Observation empirique.

- Union et intersection
- Score de confiance
- Sujet exact
- Sujet entité-partielle
- Sujet dist.
 Levenshtein
- Sujet dist. word emb.
- Sujet alias
- Sujet pronom

- Chilly Gonzales: composed:
 a global hit for the inaugural
 Apple iPad campaign
- he: had re-signed : with a major label
 it: drew : immediate
- comparisons to the work of Erik Satie
- Gonzales: wrote : musiceveryone: to sing : for me
- livre de partitions: à : jouer
- he: would win : a Grammy
 Award
- Gonzales: was born : on 20 March 1972
- Chilly Gonzales: holds: the Guinness world record for the longest solo concert at over 27 hours

- the artist: took up: residence in Europe mainly in Germany just after signing to Kitty-Yo
 he: had re-signed: with a major label
 it: drew: immediate comparisons to the work of Erik
- Satie
 he: is : songwriter
- Gonzo: shares : his point of view
- écrit des: chansons : avec Jarvis Cocker
- Gonzales: was born : on 20 March 1972
- Gonzales also known as Chilly Gonzales: is: an MC-meetskeyboarding-producer-meetssinger-extraordinaire

Conceptualisation d'heuristiques.

MÉTHODES

Observation empirique.

Heuristiques

- Union et intersection
- Score de confiance
- Sujet exact
- Sujet entité-partielle
- Sujet dist. Levenshtein
- Sujet dist. word embedding
- Sujet alias
- Sujet pronom

```
0,92 - Chilly Gonzales: composed: a global hit
for the inaugural Apple iPad campaign
0,41 - he: had re-signed: with a major label
0,27 - it: drew: immediate comparisons to the
work of Frik Satie
0.92 - Gonzales: wrote: music
0,78 - everyone: to sing: for me
0.92 - livre de partitions: à : jouer
0,50 - he: would win: a Grammy Award
0.93 - Gonzales: was born: on 20 March 1972
0.97 - Chilly Gonzales: holds: the Guinness
world record for the longest solo concert at
```

0.92 - Gonzo: shares: his point of view on

scales

Conceptualisation d'heuristiques.

MÉTHODES

Observation empirique.

Heuristiques

- Union et intersection
- Score de confiance
- Sujet exact
- Sujet entité-partielle
- Sujet dist. Levenshtein
- Sujet dist. word embedding
- Sujet alias
- Sujet pronom

0,92 - Chilly Gonzales: composed: a global hit for the inaugural Apple iPad campaign 0,41 - he: had re-signed: with a major label 0,27 - it: drew: immediate comparisons to the work of Erik Satie 0,92 - Gonzales: wrote: music 0,78 - everyone: to sing: for me 0,92 - livre de partitions: à: jouer 0,50 - he: would win: a Grammy Award 0,93 - Gonzales: was born: on 20 March 1972

0.97 - Chilly Gonzales: holds: the Guinness

world record for the longest solo concert at

0.92 - Gonzo: shares: his point of view on

scales

Conceptualisation d'heuristiques.

MÉTHODES

Observation empirique.

Heuristiques

- Union et intersection
- Score de confiance
- Sujet exact
- Sujet entité-partielle
- Sujet dist. Levenshtein
- Sujet dist. word embedding
- Sujet alias
- Sujet pronom

0,92 - Chilly Gonzales: composed: a global hit for the inaugural Apple iPad campaign 0,41 - he: had re-signed: with a major label 0,27 - it: drew: immediate comparisons to the work of Erik Satie 0,92 - Gonzales: wrote: music 0,78 - everyone: to sing: for me 0,92 - livre de partitions: à: jouer 0,50 - he: would win: a Grammy Award 0,93 - Gonzales: was born: on 20 March 1972

0.97 - Chilly Gonzales: holds: the Guinness

world record for the longest solo concert at

0.92 - Gonzo: shares: his point of view on

scales

Conceptualisation d'heuristiques.

MÉTHODES

Observation empirique.

Heuristiques

- Union et intersection
- Score de confiance
- Sujet exact
- Sujet entité-partielle
- Sujet dist. Levenshtein
- Sujet dist. word embedding
- Sujet alias
- Sujet pronom

0,92 - Chilly Gonzales: composed: a global hit for the inaugural Apple iPad campaign
0,41 - he: had re-signed: with a major label
0,27 - it: drew: immediate comparisons to the work of Erik Satie
0,92 - Gonzales: wrote: music
0,78 - everyone: to sing: for me
0,92 - livre de partitions: à: jouer
0.50 - he: would win: a Grammy Award

0.93 - Gonzales: was born: on 20 March 1972

0.97 - Chilly Gonzales: holds: the Guinness

world record for the longest solo concert at

0.92 - Gonzo: shares: his point of view on

scales

Conceptualisation d'heuristiques.

MÉTHODES

Observation empirique.

Heuristiques

- Union et intersection
- Score de confiance
- Sujet exact
- Sujet entité-partielle
- Sujet dist. Levenshtein
- Sujet dist. word embedding
- Sujet alias
- Sujet pronom

0,92 - Chilly Gonzales: composed: a global hit for the inaugural Apple iPad campaign 0,41 - he: had re-signed: with a major label 0,27 - it: drew: immediate comparisons to the work of Erik Satie 0,92 - Gonzales: wrote: music 0,78 - everyone: to sing: for me 0,92 - livre de partitions: à: jouer 0,50 - he: would win: a Grammy Award

0.93 - Gonzales: was born: on 20 March 1972

0.97 - Chilly Gonzales: holds: the Guinness

world record for the longest solo concert at

0.92 - Gonzo: shares: his point of view on

scales

Conceptualisation d'heuristiques.

MÉTHODES

Observation empirique.

Heuristiques

- Union et intersection
- Score de confiance
- Sujet exact
- Sujet entité-partielle
- Sujet dist. Levenshtein
- Sujet dist. word embedding
- Sujet alias
- Sujet pronom

0,92 - Chilly Gonzales: composed: a global hit for the inaugural Apple iPad campaign 0,41 - he: had re-signed: with a major label 0,27 - it: drew: immediate comparisons to the work of Frik Satie 0.92 - Gonzales: wrote: music 0,78 - everyone: to sing: for me 0.92 - livre de partitions: à : jouer 0.50 - he: would win: a Grammy Award 0.93 - Gonzales: was born: on 20 March 1972

0.97 - Chilly Gonzales: holds: the Guinness

world record for the longest solo concert at

0.92 - Gonzo: shares: his point of view on

scales

Conceptualisation d'heuristiques.

MÉTHODES

Observation empirique.

Heuristiques

- Union et intersection
- Score de confiance
- Sujet exact
- Sujet entité-partielle
- Sujet dist. Levenshtein
- Sujet dist. word embedding
- Sujet alias
- Sujet pronom

0,92 - Chilly Gonzales: composed: a global hit for the inaugural Apple iPad campaign 0,41 - he: had re-signed: with a major label 0,27 - it: drew: immediate comparisons to the work of Erik Satie 0.92 - Gonzales: wrote: music 0,78 - everyone: to sing: for me 0.92 - livre de partitions: à : jouer 0.50 - he: would win: a Grammy Award 0.93 - Gonzales: was born: on 20 March 1972

0.97 - Chilly Gonzales: holds: the Guinness

world record for the longest solo concert at

0.92 - Gonzo: shares: his point of view on


scales

 Expérimentations quantitatives des heuristiques.

MÉTHODES

- Recherche expérimentale.
- Analyse statistique.

Diagramme Venn des triplets de sortie OpenIE-4 capturés par les heuristiques pour l'entité Chilly Gonzales.




Catégorie	Total
Exact	4
Distance Levenshtein	5
Distance embedding (word2vec)	4
Alias	27
Partiel	24
Pronoms	28
Intersection OpenIE-4 & ClausIE	9

 Expérimentations qualitatives des heuristiques.

MÉTHODES

- Recherche expérimentale.
- Analyse statistique.

Scores de précision des heuristiques (banc d'essai Stanovsky et Dagan (2016))



Résultats

ÉTAPES

• Analyse des résultats des expériences.

MÉTHODES

Analyse statistique.

Triplets d'entrée	Heuristique	Score précision	Score Rappel
OpenIE-4	S proche distance Embedding	0.76	0.0006
OpenIE-4	S alias de E	0.84	0.004
OpenIE-4	S proche distance Embedding \cap Score de confiance > 0.9	0.77	0.001
OpenIE-4	S alias de E \cap Score de confiance > 0.9	0.88	0.003
ClauslE ∩ OpenIE-4	S proche distance Embedding	1.0	0.0001
ClauslE ∩ OpenIE-4	S alias de E	0.93	0.001
ClauslE ∩ OpenIE-4	S proche distance Embedding \cap Score de confiance > 0.9	1.0	0.0001
ClauslE ∩ OpenIE-4	S alias de E \cap Score de confiance > 0.9	0.9	0.0004

Conclusions



Contributions

- Analyse comparative des complémentarités (strictes) entre:
 - des faits de KB choisies.
 - des triplets de sortie d'OIE choisis.
 - des faits de KB choisies et des triplets de sortie d'OIE choisis
- Évaluation d'heuristiques appliquées sur des triplets de sortie OIE.

Perspectives

- Approfondir dans l'analyse statistique entre faits de KB et triplets de sortie OIE.
- Concevoir un banc d'essai plus complet.
- Poursuivre la recherche de meilleures heuristiques ou métaheuristiques.
- Tester l'efficacité des réseaux de neuronnes ou des modèles statistiques vs. l'efficacité des heuristiques.
- Concevoir, développer et tester une KB à faits subjectifs.

Références capitales



Xin Dong et al. (2014)

Knowledge Vault: A Web-scale Approach to Probabilistic Knowledge **Fusion**

Proceedings of the 20th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 601 – 610.



Gabriel Stanovsky et Ido Dagan (2016)

Creating a large benchmark for open information extraction Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing (EMNLP).



Mausam (2016)

Open Information Extraction Systems and Downstream Applications Proceedings of the Twenty-Fifth International Joint Conference on Artificial Intelligence, 4074 – 4077.




Questions




Schema du mémoire.

Schéma du banc d'essai de Stanovsky et Dagan (2016) en n'utilisant que le corpus extrait de Wikipédia.



Schema du mémoire



Catégorie	Total
Exact	8
Distance Levenshtein	22
Distance embedding (word2vec)	58
Alias	51
Partiel	92
Pronoms	265

Schema du mémoire.

